

INFORME DE ANÁLISIS EXPLORATORIO DE DATOS

DATASET: MOVIELENS ML-LATEST-SMALL

=====

Este informe responde las cinco preguntas principales del EDA.

Los valores fueron calculados directamente desde los archivos CSV.

=====

1. ¿QUÉ DATOS TENGO?

=====

El dataset contiene información de películas, calificaciones, etiquetas y enlaces externos.

Archivo: movies.csv

Descripción: Información de películas y géneros

Filas: 9,742

Columnas: 3

Variables: movieId, title, genres

Archivo: ratings.csv

Descripción: Calificaciones dadas por usuarios

Filas: 100,836

Columnas: 4

Variables: userId, movieId, rating, timestamp

Archivo: tags.csv

Descripción: Etiquetas asignadas por usuarios

Filas: 3,683

Columnas: 4

Variables: userId, movieId, tag, timestamp

Archivo: links.csv

Descripción: Enlaces externos de películas

Filas: 9,742

Columnas: 3

Variables: movieId, imdbId, tmdbId

Interpretación:

El conjunto contiene 100,836 calificaciones, 3,683 aplicaciones válidas de etiquetas y 9,742 películas.

=====

2. ¿HAY DATOS FALTANTES?

=====

Se encontraron los siguientes problemas:

- links.csv / tmdbId: 8 faltantes (0.08%) y 0 cadenas vacías.

Archivo detallado generado: missing_values.csv

=====

3. ¿EXISTEN VALORES ATÍPICOS?

=====

Se utilizó el método del rango intercuartílico (IQR). Un valor se considera atípico si queda fuera de $Q1 - 1.5 \times IQR$ o $Q3 + 1.5 \times IQR$.

Variable: Valor de rating

¿Tiene atípicos?: Sí

Q1: 3.00

Q3: 4.00

IQR: 1.00

Límite inferior: 1.50

Límite superior: 5.50

Cantidad de atípicos: 4,181

Porcentaje de atípicos: 4.15%

Variable: Ratings por usuario

¿Tiene atípicos?: Sí

Q1: 35.00

Q3: 168.00

IQR: 133.00

Límite inferior: -164.50

Límite superior: 367.50

Cantidad de atípicos: 70

Porcentaje de atípicos: 11.48%

Variable: Ratings por película

¿Tiene atípicos?: Sí

Q1: 1.00

Q3: 9.00

IQR: 8.00

Límite inferior: -11.00

Límite superior: 21.00

Cantidad de atípicos: 1,179

Porcentaje de atípicos: 12.12%

Variable: Tags por usuario

¿Tiene atípicos?: Sí

Q1: 2.25

Q3: 13.00

IQR: 10.75

Límite inferior: -13.88

Límite superior: 29.12

Cantidad de atípicos: 12

Porcentaje de atípicos: 20.69%

Variable: Tags por película

¿Tiene atípicos?: Sí

Q1: 1.00

Q3: 2.00

IQR: 1.00

Límite inferior: -0.50

Límite superior: 3.50

Cantidad de atípicos: 225

Porcentaje de atípicos: 14.31%

Variable: Usos por etiqueta

¿Tiene atípicos?: Sí

Q1: 1.00

Q3: 2.00

IQR: 1.00

Límite inferior: -0.50

Límite superior: 3.50

Cantidad de atípicos: 235

Porcentaje de atípicos: 15.93%

Variable: Géneros por película

¿Tiene atípicos?: Sí

Q1: 1.00

Q3: 3.00

IQR: 2.00

Límite inferior: -2.00

Límite superior: 6.00

Cantidad de atípicos: 14

Porcentaje de atípicos: 0.14%

Archivo detallado generado: outliers_iqr.csv

=====

4. ¿CÓMO SE DISTRIBUYEN LOS DATOS?

=====

Distribución de etiquetas:

Aplicaciones totales: 3,683

Aplicaciones válidas: 3,683

Etiquetas únicas: 1,475

Promedio de usos por etiqueta: 2.50

Mediana de usos por etiqueta: 1.00

Desviación estándar: 4.70

Menor frecuencia: 1

Mayor frecuencia: 131

Top 10 etiquetas: 358 usos (9.72% del total)

Top 20 etiquetas: 551 usos (14.96% del total)

Top 50 etiquetas: 939 usos (25.50% del total)

Top 100 etiquetas: 1,366 usos (37.09% del total)

Distribución de calificaciones:

Promedio: 3.50

Mediana: 3.50

Mínima: 0.5

Máxima: 5.0

Interpretación: revise los gráficos generados para observar si las distribuciones son uniformes, concentradas o de cola larga.

=====

5. ¿QUÉ RELACIONES EXISTEN ENTRE VARIABLES?

=====

Se analizaron relaciones mediante agrupaciones por usuario y película.

Cobertura del dataset:

Usuarios con ratings: 610

Usuarios con tags: 58

Películas con ratings: 9,724

Películas con tags: 1,572

Usuarios con más ratings:

1. userId: 414 | Cantidad: 2,698
2. userId: 599 | Cantidad: 2,478
3. userId: 474 | Cantidad: 2,108
4. userId: 448 | Cantidad: 1,864
5. userId: 274 | Cantidad: 1,346
6. userId: 610 | Cantidad: 1,302
7. userId: 68 | Cantidad: 1,260
8. userId: 380 | Cantidad: 1,218
9. userId: 606 | Cantidad: 1,115

10. userId: 288 | Cantidad: 1,055

Películas con más ratings:

1. movied: 356 | Cantidad: 329
2. movied: 318 | Cantidad: 317
3. movied: 296 | Cantidad: 307
4. movied: 593 | Cantidad: 279
5. movied: 2571 | Cantidad: 278
6. movied: 260 | Cantidad: 251
7. movied: 480 | Cantidad: 238
8. movied: 110 | Cantidad: 237
9. movied: 589 | Cantidad: 224
10. movied: 527 | Cantidad: 220

Usuarios con más tags:

1. userId: 474 | Cantidad: 1,507
2. userId: 567 | Cantidad: 432
3. userId: 62 | Cantidad: 370
4. userId: 599 | Cantidad: 323
5. userId: 477 | Cantidad: 280
6. userId: 424 | Cantidad: 273
7. userId: 537 | Cantidad: 100
8. userId: 125 | Cantidad: 48
9. userId: 357 | Cantidad: 45
10. userId: 318 | Cantidad: 41

Películas con más tags:

1. movied: 296 | Cantidad: 181
2. movied: 2959 | Cantidad: 54
3. movied: 924 | Cantidad: 41

4. movied: 293 | Cantidad: 35
5. movied: 7361 | Cantidad: 34
6. movied: 1732 | Cantidad: 32
7. movied: 4878 | Cantidad: 29
8. movied: 260 | Cantidad: 26
9. movied: 79132 | Cantidad: 26
10. movied: 135536 | Cantidad: 19

Correlación entre cantidad de ratings y tags por usuario: 0.3579

Interpretación: una correlación positiva indica que los usuarios que califican más películas tienden también a crear más etiquetas.

Nota: userId y movied son identificadores, por lo que no se debe interpretar su correlación numérica directa.

=====

ARCHIVOS GENERADOS

=====

Reportes CSV:

- data_summary.csv
- missing_values.csv
- outliers_iqr.csv
- user_activity.csv
- movie_activity.csv

Gráficos PNG:

- distribution_ratings.png
- distribution_tag_frequency.png
- movie_genres.png
- outliers_tag_frequency.png

- ratings_by_year.png
- relationship_user_activity.png
- tags_by_year.png
- top_20_tags.png
- top_tags.png

Referencia del dataset:

F. Maxwell Harper y Joseph A. Konstan, 2015.

The MovieLens Datasets: History and Context.

=====